Auswertung von Sequenzier-Ergebnissen (erste Visualisierungen)

(Bio)Conda

- Bioconda dient als Distributionsplattfprm ("Spielwiese") = Environment
- ist ein Paket- und Umgebungsmanager
- damit kann Softwaren installiert, Abhängigkeiten verwantet und isolierte Umgebungen geschaffen werden
- zum Beispiel: NanoComp oder Nanoplot installieren

Conda	Bioconda
Werkzeug zum Installieren und Verwalten von Software	große sammlung von Bioformatik-Programmen für Conda

BioConda:

- erstellt eine reproduzierbare Umgebung
- sorgt für eine einfach Installion (bioinformatischer Tools)

NanoPlot zur Seqeunzieranalyse

- für Oxford-Nanopore-Seqeunzdaten (ONT)
- Tool zur Qualitätskontrolle und Visulisierung von Seqeunzdaten
- analysiert einen einzelnen Datensatz/Lauf im Detail
- anylsierte *basecallte Reads* (aus FastQ-/ BAM-Dateien)

NanoPlot hilft zu beurteilen...

- wie gut ein Sequenzierlauf war
- ob die Daten für weitere Analysen geeignet sind
- ob Library-Prep/ Flowcell gut funktioniert haben
- ob ein Run wiederholt werden sollte

NanoComp zur Seqeunzieranalyse

- zum Vergleich von Oxford-Nanopore-Sequenzierungsdaten und Ausrichtungen
- dient dazu mehrere Sequnezierläufe oder Proben miteinander zu vergleichen

NanoComp führt *vergleichende Qualitätskontrolle (QC)* durch. Es analysiert typischerweise *bereits basecallte Reads* (z.B. FASTQ) oder Sequenzier-Summary-Dateien und erstellt

Statistiken und Plots.

NanoComp ...

- führt vergleichende Qualitätskontrollen durch
- analysiert bereits basecallte Reads (z.B. FASTQ) oder Seqeunzier-Summary-Dateien
- erstellt Statistiken und Plots

NanoPlot	NanoComp
Visualisierung für einen Datensatz	vergleich mehrerer Datensätze
Plottwerkzeug für Longread-Sequenzierungsdaten; es wird eine Datei erstellt, die die wichtigsten Merkmale des Datensatzes zusammenfasst	vergleicht mehrere Durchläufe von Longread-Sequenzierungsdaten; Erstellt Geigendiagramme oder Boxdiagramme mit Länge, Qualität und prozentualer Identität, aber auch dynamische, überlagernde Leselängenhistogramme sowie ein kumulatives Renditediagramm

Vorbereitung zu Auswertung von Sequenzierungen

1. Arbeitsumgebung mit Conda schaffen

! im JupyterNotebook ist Conda bereits installiert, deswegen muss nur noch ein Environment erstellt und die gewünschten Pakete installiert werden

1.1. Environment schaffen:

conda create -n *gewünschten Namen der Arbeitsumgebung*

In [ ]:
```
z.B.: conda create -n nanoplot
```

1.2. Environmnet aktivieren:

conda activate *gewünschte bereits erstelles Environment*

In [ ]:
```
z.B.: conda activate nanoplot
```

- conda wird ausgeführt = Abkürzung "base" zubeginn in der Kommandozeile
- "Spielwiese" nanoplot aktieren = Abkürzung "nanoplot" zubeginn in der Kommandozeile

In [ ]:
```
(base) ...$ conda activate nanoplot
(nanoplot) ...$
```

weitere Befehle für das Arbeiten mit Environmnet:

In [ ]:
```
# alle Environmnets anzeigen lassen
conda env list

# in dem aktivierten Environment ein Tool installieren
conda install -c (Befehl = z.B.: bioconda::nanoplot)
```

2. Installieren von Nanoplot

2.1. Environment für NanoPlot schaffen:

conda create -n nanoplot

In [ ]:
```
Collecting package metadata (current_repodata.json): done
Solving environment: done
^C

Note: you may need to restart the kernel to use updated packages.
```

In [ ]:
```
# To activate this environment, use
#
#     $ conda activate nanoplot
#
# To deactivate an active environment, use
#
#     $ conda deactivate
```

Environment nanocomp aktieren:

In [ ]:
```
(base) ...$ conda activate nanoplot
(nanoplot) ...$
```

2.2. NanoPlot installieren:

Webseite zur Installation von Nanoplot:
https://anaconda.org/channels/bioconda/packages/nanoplot/overview

conda install bioconda::nanoplot

In [ ]:
```
(base) ...$ conda activate nanoplot
(nanoplot) ...$ mamba install bioconda::nanoplot
```

! Hier wurde *mamba* verwendet = ist wie conda, nur schneller

2.3. Kontrollieren, dass Nanoplot instaliert wurde:

NanoPlot oder NanoPlot -h

In [ ]:
```
(nanoplot) ...$ NanoPlot
usage: NanoPlot [-h] [-v] [-t THREADS] [--verbose] [--store] [--raw] [--huge] [-
                [--maxlength N] [--minlength N] [--drop_outliers] [--downsample
                [--readtype {1D,2D,1D2}] [--barcoded] [--no_supplementary] [-c C
                [--plots [{kde,hex,dot} ...]] [--legacy [{kde,dot,hex} ...]] [--
                [--dpi DPI] [--hide_stats] (--fastq file [file ...] | --fasta fi
```

```
                 --summary file [file ...] | --bam file [file ...] | --ubam file
NanoPlot: error: one of the arguments --fastq --fasta --fastq_rich --fastq_minim
```

! Zur Vorsicht kann immer vor den Befehl "conda activate nanoplot" geschrieben werden

3. Installieren von NanoComp

3.1. Environment für NanoComp schaffen:

conda create -n nanocomp

In [ ]:
```
Preparing transaction: done
Verifying transaction: done
Executing transaction: done
#
# To activate this environment, use
#
#     $ conda activate nanocomp
#
# To deactivate an active environment, use
#
#     $ conda deactivate
```

Environment nanocomp aktieren:

In [ ]:
```
(nanoplot) ...$ conda activate nanocomp
(nanocomp) ...$
```

3.2. NanoComp installieren:

Webseite zur Installation von Nanoplot:
https://anaconda.org/channels/bioconda/packages/nanocomp/overview

conda install bioconda::nanocomp

In [ ]:
```
(nanoplot) ...$ conda activate nanocomp
(nanocomp) ...$ mamba install bioconda::nanocomp
```

! auch hier wurde *mamba* für eine schnellere installation verwendet

3.3. Kontrollieren, dass NanoComp instaliert wurde:

NanoComp oder NanoComp -h

In [ ]:
```
(nanocomp) ...$ NanoComp -h
usage: NanoComp [-h] [-v] [-t THREADS] [-o OUTDIR] [-p PREFIX] [--verbose] [--ra
                [--minlength N] [--barcoded] [--split_runs TSV_FILE] [-f [{png,j
                [--plot {violin,box,ridge,false}] [--title TITLE] [--dpi DPI] (-
                --summary files [files ...] | --bam files [files ...] | --ubam f
                --feather file [file ...])

Compares long read sequencing datasets.

General options:
```

```
  -h, --help            show the help and exit
  -v, --version         Print version and exit.
  -t, --threads THREADS
                        Set the allowed number of threads to be used by the scri
  -o, --outdir OUTDIR   Specify directory in which output has to be created.
  -p, --prefix PREFIX   Specify an optional prefix to be used for the output fil
  --verbose             Write log messages also to terminal.
  --raw                 Store the extracted data in tab separated file.
  --store               Store the extracted data in a pickle file for future plo
  --tsv_stats           Output the stats file as a properly formatted TSV.
  --make_no_static      Do not make static (png) plots.

Options for filtering or transforming input prior to plotting:
  --readtype {1D,2D,1D2}
                        Which read type to extract information about from summar
                        1D2
  --maxlength N         Drop reads longer than length specified.
  --minlength N         Drop reads shorter than length specified.
  --barcoded            Barcoded experiment in summary format, splitting per bar
  --split_runs TSV_FILE
                        File: Split the summary on run IDs and use names in tsv
                        fields are 'NAME' and 'RUN_ID'.

Options for customizing the plots created:
  -f, --format [{png,jpg,jpeg,webp,svg,pdf,eps,json} ...]
                        Specify the output format of the plots, which are in add
  -n, --names names [names ...]
                        Specify the names to be used for the datasets
  -c, --colors colors [colors ...]
                        Specify the colors to be used for the datasets
  --plot {violin,box,ridge,false}
                        Which plot type to use: 'box', 'violin' (default), 'ridg
                        (no plots)
  --title TITLE         Add a title to all plots, requires quoting if using spac
  --dpi DPI             Set the dpi for saving images (deprecated)

Input data sources, one of these is required.:
  --fasta file [file ...]
                        Data is in (compressed) fasta format.
  --fastq files [files ...]
                        Data is in (compressed) fastq format.
  --fastq_rich file [file ...]
                        Data is in one or more fastq file(s) generated by MinKNO
                        additional information concerning channel and time.
  --summary files [files ...]
                        Data is in (compressed) summary files generated by guppy
  --bam files [files ...]
                        Data is in sorted bam files.
  --ubam file [file ...]
                        Data is in one or more unmapped bam file(s).
  --cram file [file ...]
                        Data is in one or more sorted cram file(s).
  --pickle file [file ...]
                        Data is in one or more pickle file(s) from using NanoCom
  --feather, --arrow file [file ...]
                        Data is in one or more feather file(s).

EXAMPLES:
    NanoComp --bam alignment1.bam alignment2.bam --outdir compare-runs
    NanoComp --fastq reads1.fastq.gz reads2.fastq.gz reads3.fastq.gz  --names ru
```

Skript für die Auswertung der ersten Sequenzierung (Gos1)

- Sequenzierung mittels Rapid Barcoding Kit 24
- FlowCell hatte 25 aktive Poren

Probe	Barcode	Quibit [ng/µl]
Gos1_2_2	BC01	too low
Gos1_2_3	BC02	0.356
Gos1_2_4	BC03	2.02
Gos1_2_5	BC04	0.142
Gos1_2_6	BC05	too low
Gos1_2_7	BC06	too low
Gos1_2_8	BC07	too low
Gos1_3_1	BC08	too low
Gos1_3_2	BC09	too low

1. Vorbereitungen

- kontrollieren, dass auf alle Funktionen Zugriff gewährt ist (alle Zugriffsrechte gegeben)
- gewünschte zu bearbeitende Daten sind in dem entsprechenden "Arbeitsordner" hinterlegt (z.B. auf dem Server)
- kontrolle des Arbeitsverzeichnisses und die Auswahl des gewünschten Ordners wurde getroffen

- hochgeladene Datei auf Vorhandensein überprüfen: cat ./sequencing_summary_AWG955_5f8968e3_4a72e1a0.txt | head

In [ ]:
```
filename_fastq  filename_fast5  filename_pod5   parent_read_id  read_id run_id
AWG955_fail_unclassified_5f8968e3_4a72e1a0_0.fastq.gz   AWG955_fail_unclassified
AWG955_fail_unclassified_5f8968e3_4a72e1a0_0.fastq.gz   AWG955_fail_unclassified
AWG955_fail_unclassified_5f8968e3_4a72e1a0_0.fastq.gz   AWG955_fail_unclassified
AWG955_fail_unclassified_5f8968e3_4a72e1a0_0.fastq.gz   AWG955_fail_unclassified
AWG955_fail_unclassified_5f8968e3_4a72e1a0_0.fastq.gz   AWG955_fail_unclassified
AWG955_fail_unclassified_5f8968e3_4a72e1a0_0.fastq.gz   AWG955_fail_unclassified
AWG955_fail_unclassified_5f8968e3_4a72e1a0_0.fastq.gz   AWG955_fail_unclassified
AWG955_fail_unclassified_5f8968e3_4a72e1a0_0.fastq.gz   AWG955_fail_unclassified
AWG955_fail_unclassified_5f8968e3_4a72e1a0_0.fastq.gz   AWG955_fail_unclassified
```

2. Nanoplot Anwednung auf die Sequenzdaten

2.1. Arbeitsverzeichnis kontrollieren und anpassen

2.2. Environmnet aktivieren (und Tool prüfen):

In [ ]:
```
(base) ...$ conda activate nanoplot
(nanoplot) ...$ NanoPlot
usage: NanoPlot [-h] [-v] [-t THREADS] [--verbose] [--store] [--raw] [--huge] [-
                [--maxlength N] [--minlength N] [--drop_outliers] [--downsample
                [--readtype {1D,2D,1D2}] [--barcoded] [--no_supplementary] [-c C
                [--plots [{kde,hex,dot} ...]] [--legacy [{kde,dot,hex} ...]] [--
                [--dpi DPI] [--hide_stats] (--fastq file [file ...] | --fasta fi
                --summary file [file ...] | --bam file [file ...] | --ubam file
NanoPlot: error: one of the arguments --fastq --fasta --fastq_rich --fastq_minim
```

2.3. NanoPlot ausführen:

Internetseite für weitere Informationen: https://github.com/wdecoster/NanoPlot

In [ ]:
```
(nanoplot) ...$ NanoPlot --summary ./sequencing_summary_AWG955_5f8968e3_4a72e1a0
```

Ausgeführter **NanoPlot** Befehl erzeugt Dateien im gewünschten Ordner (im Server)

- bei Fehlermeldungen die rechte kontrollieren und zur Not noch einmal anpassen
- Ordner in "Organisator = WinSCP" aktuallieren = sollten alle NanoPlot-Ausgaben erkennbar sein

3. NanoComp Anwendung auf die Sequenzdaten

3.1. Arbeitsverzeichnis kontrollieren und anpassen

3.2. Environmnet aktivieren (und Tool prüfen):

In [ ]:
```
(base) ...$ conda activate nanocomp
(nanocomp) ...$ NanoComp
usage: NanoComp [-h] [-v] [-t THREADS] [-o OUTDIR] [-p PREFIX] [--verbose] [--ra
                [--minlength N] [--barcoded] [--split_runs TSV_FILE] [-f [{png,j
                [--plot {violin,box,ridge,false}] [--title TITLE] [--dpi DPI] (-
                --summary files [files ...] | --bam files [files ...] | --ubam f
                --feather file [file ...])
NanoComp: error: one of the arguments --fasta --fastq --fastq_rich --summary --b
```

3.3. NanoComp mit den "sequencing_summery"-Daten ausführen:

! Dateien die genutzt werden sind bereits im Verzeichnis von Server hinterlegt

- Internetseite für weitere Informationen: https://github.com/wdecoster/NanoComp

Arbeistverzeichnis wechseln:

In [ ]:
```
(nanocomp) ...$ cd ./summary/
(nanocomp) .../summary$
```

Nachdem Auswählen des passenden Arbeitsverzeichnisses kann **NanoComp** *summary* durchgeführt werden

In [ ]:
```
(nanocomp) .../summary$ NanoComp --summary ./sequencing_summary_AWG955_5f8968e3_
(nanocomp) .../summary$
```

Ausgeführter **NanoComp** Befehl erzeugt Dateien im Ordner auf dem Server

3.4. NanoComp mit den "Barcode"-Daten ausführen:

Arbeitsverzeichnis wechseln:

In [ ]:
```
(nanocomp) .../summary$ cd ./barcodes/
(nanocomp) .../barcodes$
```

! *.gz Barcode-Dateien* in den Ordner des Servers laden (Wichtig: In das passende Arbeitsverzeichnis in dem gearbeitet wird und in dem die neuen Dateien entstehen)

Ausführen des **NanoComp** Befehls mit einladen der einzelnen *Barcode-Dateien*:

In [ ]:
```
(nanocomp) .../barcodes$ NanoComp --fastq ./AWG955_pass_barcode01_5f8968e3_4a72e


WARNING: less than 5 reads in the dataset!
WARNING: some stats might be unexpected or missing
WARNING: or a crash might happen, who knows
WARNING: this code is not intended for such small datasets
```

! nach der Aktualisierung von WinSCP sind alle Dokumente die erstellt wurden vorhanden (Warnung hat nur noch mal verdeutlicht, dass es keine tollen Ergebnisse sind)

Fertig